

ΓΡΑΦΟΙ ΚΑΙ ΑΝΑΛΥΣΗ ΔΙΚΤΥΩΝ

Κατηγοριοποίηση Γράφων: Από Μετρικές σε Νευρωνικά Δίκτυα

Μια συγκριτική μελέτη μεθόδων αναπαράστασης και ταξινόμησης βιολογικών δικτύων.

ΦΟΙΤΗΤΗΣ

Γιώργος Πουλημένος (ΑΜ: 25113)

ΔΙΔΑΣΚΩΝ

Δημήτρης Μιχαήλ

ΣΥΝΟΛΟ ΔΕΔΟΜΕΝΩΝ

PROTEINS Dataset

| Επισκόπηση Μεθοδολογίας



Μέθοδος Α

Εξαγωγή 14 καθολικών τοπολογικών και βιολογικών χαρακτηριστικών (Handcrafted) και επακόλουθη ταξινόμηση μέσω MLP.



Μέθοδος Β

Representation Learning με Node2Vec embeddings, Hyperparameter Tuning, βελτιστοποίηση με SCL και χρήση MLP.



Μέθοδος Γ

End-to-end Graph Neural Networks (GraphSAGE) για απευθείας εκμάθηση από την τοπολογία των πρωτεϊνών.

| Το Σύνολο Δεδομένων PROTEINS

Χαρακτηριστικά Δομής Πρωτεϊνών

1113

ΣΥΝΟΛΙΚΟΙ
ΓΡΑΦΟΙ

2

ΚΛΑΣΕΙΣ
(ΕΝΖΥΜΑ / ΜΗ)

3

NODE FEATURES
(SSE)

Το PROTEINS είναι ένα κλασικό βιολογικό dataset για binary graph classification. Οι κόμβοι αντιπροσωπεύουν δευτεροταγείς δομές πρωτεϊνών (SSE) και οι ακμές τις φυσικές αποστάσεις μεταξύ τους.



Τα node features είναι One-Hot Encoded, αντιπροσωπεύοντας δευτεροταγείς δομές (SSE).



Διαχωρισμός ανάμεσα σε Ένζυμα και Μη-Ένζυμα.

| Δομική Ανάλυση & Προκατάληψη



Μορφολογική Απόκλιση

Παρατηρείται έντονη διαφορά στο μέγεθος των γράφων μεταξύ των κλάσεων:

- **Κλάση 0 (Μη-ένζυμα):** Μέσο μέγεθος ~50 κόμβοι.
- **Κλάση 1 (Ένζυμα):** Μέσο μέγεθος ~23 κόμβοι.

Κίνδυνος: Shortcut Learning βασισμένο στο μέγεθος αντί της καθαρής τοπολογίας.



Δίκτυο "Small-World"

Οι γράφοι των πρωτεϊνών εμφανίζουν χαρακτηριστικά συμπαγούς Small-World δικτύου:



Avg Degree: ~3.7 (Σταθερότητα 3D αναδίπλωσης)



Clustering Coeff: 0.34 (Ισχυρά τοπικά μοτίβα)



Avg Path Length: 5.36 (Συμπαγής δομή)

| Μέθοδος A: Handcrafted Features



Δομικά & Τοπολογικά

- Δομικά
 - Πλήθος κόμβων/ακμών,
 - Πυκνότητα,
 - Κλίκες,
 - Τρίγωνα,
 - Transitivity
- Τοπολογικά
 - Diameter,
 - Wiener Index,
 - Centrality.



Φασματικά

- Algebraic Connectivity (Fiedler Value) για την αποτύπωση της συνεκτικότητας του γράφου.



Βιολογικά

- Helix Ratio: Ποσοστό εμφάνισης α-ελίκων.
- Sheet Ratio: Ποσοστό εμφάνισης β-πτυχωτών επιφανειών.
- Turn Ratio: Ποσοστό εμφάνισης στροφών.


| Σημαντικότητα Χαρακτηριστικών

Forward Feature Selection

Εφαρμόστηκε αλγόριθμος Forward Feature Selection με στόχο την εύρεση της βέλτιστης υποομάδας που μεγιστοποιεί την απόδοση ταξινόμησης.

✓ **Βέλτιστο Υποσύνολο:** 8 χαρακτηριστικά επιλέχθηκαν τελικά για το μοντέλο MLP.

★ **F1-Macro:** Χρησιμοποιήθηκε ως η κύρια μετρική αξιολόγησης και βελτιστοποίησης για την εύρεση του βέλτιστου υποσυνόλου.



➤ **Selected Features:**
Συντελεστής Ομαδοποίησης, Τριγωνά, Διάμετρος, Algebraic connectivity, Betweenness, Sheet ratio, Turn ratio

| Αποτελέσματα Μεθόδου A


Η ισχύς της Γνώσης Πεδίου

Η Μέθοδος A (Handcrafted Features) λειτουργεί ως ένα εξαιρετικά ισχυρό baseline για την εργασία.


ΚΥΡΙΟ ΣΥΜΠΕΡΑΣΜΑ

Η Πυκνότητα (Density) και τα Φασματικά χαρακτηριστικά είναι οι κυριότεροι διαχωριστικοί δείκτες για τα ένζυμα.

Η ενσωμάτωση βιολογικής πληροφορίας (SSE Ratios) προσφέρει απαραίτητο πλαίσιο που βοηθά το MLP να διακρίνει τις δομικές διαφορές.




Αποτελέσματα Μεθόδου A -Ανάλυση Features




Συμπέρασμα:
Η Πυκνότητα και τα Φασματικά
χαρακτηριστικά είναι οι
κυριότεροι διαχωριστικοί δείκτες
για τα ένζυμα.

Αποτελέσματα Κωδικά	
Feature Group	F1-Macro Score
Advanced/Spectral	0.7149
Size & Scale	0.7104
Connectivity/Density	0.6991
Local Topology	0.6883

TOP FEATURES IMPACT (Contribution to overall F1)	
avg_degree	: +0.0026 boost
transitivity	: +0.0056 boost
n_triangles	: +0.0058 boost
alg_conn	: +0.0163 boost
density	: +0.0266 boost



Μέθοδος B: Shallow Embeddings



Μάθηση Αναπαραστάσεων

Εφαρμογή Node2Vec (μέσω τυχαίων περιπάτων) για την εξαγωγή τοπικών δομικών σχέσεων των κόμβων και Max Pooling για τη δημιουργία graph-level embeddings.

Winning Configuration:

Dimension: 128 | Walk Length: 20 | Pooling: Max

| Η Επίδραση του Contrastive Loss



Plain Node2Vec

Υποφέρει από Shortcut Learning.

- ✗ **Recall Ενζύμων:** μόλις 52.94%
- ✗ Το μοντέλο τείνει να προβλέπει συστηματικά την πλειοψηφούσα κλάση (bias μεγέθους).



With Contrastive SCL


Ευθυγράμμιση embeddings με τις κλάσεις.

- ✓ **Recall Ενζύμων:** 69.12%
- ✓ Εξαιρετικά σημαντική βελτίωση στην αναγνώριση των ενζύμων χωρίς απώλεια γενίκευσης.

Η Επίδραση του Contrastive Loss


✗ Plain Node2Vec

Κλάση / Δείκτης	Precision	Recall	F1-Score	Support
Μη-Ένζυμα (Non-Enzymes)	0.74	0.91	0.81	99
Ένζυμα (Enzymes)	0.80	0.53	0.64	68
Συνολική Ακρίβεια (Accuracy)	-	-	0.75	167
Macro Avg	0.77	0.72	0.73	167
Weighted Avg	0.76	0.75	0.74	167



✓ With Contrastive SCL

Κλάση / Δείκτης	Precision	Recall	F1-Score	Support
Μη-Ένζυμα (Non-Enzymes)	0.77	0.72	0.74	99
Ένζυμα (Enzymes)	0.63	0.69	0.66	68
Συνολική Ακρίβεια (Accuracy)	-	-	0.71	167
Macro Avg	0.70	0.70	0.70	167
Weighted Avg	0.71	0.71	0.71	167



| Supervised Contrastive Learning

//

"Ελξη ομοίων — Απώθηση ανομοίων"

Η φιλοσοφία πίσω από τη βελτιστοποίηση του λανθάνοντος χώρου (SCL)

Η SCL αναγκάζει το νευρωνικό δίκτυο να συμπίεσει τις αναπαραστάσεις των γράφων που ανήκουν στην ίδια κλάση (ένζυμα) και να αυξήσει την απόσταση από τις αναπαραστάσεις της διαφορετικής κλάσης στον χώρο των embeddings.



Οπτικοποίηση t-SNE (Test Set)

Χαρτογράφηση του Λανθάνοντος Χώρου

Η σύγκριση των t-SNE projections αποδεικνύει την επίδραση της μεθόδου:

Plain Node2Vec: Εμφανίζει μια άμορφη κατανομή με έντονο θόρυβο και αλληλοεπικάλυψη κλάσεων.

Node2Vec + Contrastive: Δημιουργεί μια ξεκάθαρη τάση διαχωρισμού των κλάσεων σε διακριτά clusters.



Μέθοδος Γ: GNN Classification

Αρχιτεκτονική GraphSAGE


Χρήση End-to-End Graph Neural Networks για απευθείας εξαγωγή πληροφορίας από την τοπολογία χωρίς manual feature engineering.



Grid Search: Εκτενές hyperparameter tuning για τον προσδιορισμό της ιδανικής αρχιτεκτονικής.



Layers & Pooling: 3 Layers, Hidden Dim 128, Mean Pooling.



| Βέλτιστη Ρύθμιση & Validation



0.79


VALIDATION F1-SCORE



Παράμετροι Εκπαίδευσης

- ✓ Αριθμός Επιπέδων (Layers): 3
- ✓ Κρυφή Διάσταση (Hidden Dim): 128
- ✓ Μέθοδος Pooling: Mean Pooling


Βέλτιστη Ρύθμιση & Validation



Test Loss: 0.6081, Test Accuracy: 0.6826, Test F1-Macro: 0.6356





FINAL GNN CLASSIFICATION REPORT (Test Set)

	precision	recall	f1-score	support
Non-Enzyme	0.68	0.88	0.77	99
Enzyme	0.69	0.40	0.50	68



Συγκριτικός Πίνακας

Μεθοδολογία	F1-Macro (Test)	Recall (Enzymes)	Βασικό Πλεονέκτημα
Μέθοδος Α (Handcrafted)	0.7632	67.50%	Domain Knowledge
Μέθοδος Β (Plain Node2Vec)	0.6210	52.94%	Unsupervised Representations
Μέθοδος Β (Node2Vec + SCL)	0.7145	69.12%	Balanced & Robust latent space
Μέθοδος Γ (GraphSAGE)	0.6820	40.00%	End-to-End Latent Topology



| Συγκριτική Αξιολόγηση



Κυριαρχία της Γνώσης Πεδίου (Μέθοδος Α): Τα χειροκίνητα χαρακτηριστικά (SSE Ratios) προσφέρουν την πιο συμπαγή και διακριτική πληροφορία, επιτυγχάνοντας το κορυφαίο F1-Macro (0.7632).



SCL ως Ρυθμιστής Χώρου (Μέθοδος Β): Η αντιπαραβολική μάθηση έσπασε το Shortcut Learning. Εκτόξευσε το Recall των ενζύμων στο 69.12% (+16% έναντι της Plain), προσφέροντας το πιο ισορροπημένο μοντέλο.



Η Αδυναμία των GNNs (Μέθοδος Γ): Η end-to-end μάθηση από τη γυμνή τοπολογία υπέφερε από Class Imbalance Bias (Recall Ενζύμων μόλις 40.00%), λόγω έλλειψης δομικής προ-εκπαίδευσης.

| Τελικά Συμπεράσματα



Feature Engineering

Παραμένει η πιο αξιόπιστη μέθοδος (F1: 0.76) λόγω της άμεσης αξιοποίησης βιολογικών χαρακτηριστικών.



Representation Learning

Το απλό Node2Vec αποτυγχάνει στα ένζυμα λόγω shortcut learning, αλλά το Contrastive SCL διορθώνει επιτυχώς τη συμπεριφορά του.

Ευχαριστώ πολύ!

Γεώργιος Πουλημένος

Γράφοι και Ανάλυση Δικτύων | 2024



Ερωτήσεις & Συζήτηση